

# Máquina de Soporte Vectorial en paralelo.

# Clasificación.

# Clasificación.

- Modelo lineal de clasificación.

# Clasificación.

- Modelo lineal de clasificación.
- Sean  $\mathcal{C}_0, \mathcal{C}_1$  dos clases y  $\mathbf{x} \in \mathbb{R}^n$  un vector de atributos. Se desea clasificar al vector  $\mathbf{x}$  en alguna de las dos clases ajenas de modo que se tenga el menor error de clasificación.

# Clasificación.

- Modelo lineal de clasificación.
- Sean  $\mathcal{C}_0, \mathcal{C}_1$  dos clases y  $\mathbf{x} \in \mathbb{R}^n$  un vector de atributos. Se desea clasificar al vector  $\mathbf{x}$  en alguna de las dos clases ajenas de modo que se tenga el menor error de clasificación.
- Problemas de este tipo surgen naturalmente en medicina (cáncer), finanzas (crédito), computación (spam),...


# MSV.

# MSV.

- Supóngase que se tienen  $m$  individuos a los que se desea clasificar en  $\mathcal{C}_0, \mathcal{C}_1$  y para cada individuo sean  $\mathbf{x}_i \in \mathbb{R}^n$  su correspondiente vector de atributos  $i = 1, 2, \dots, m$  y el vector de etiquetas  $\hat{\mathbf{y}} = (\hat{y}_i)_{i=1}^m \in \mathbb{R}^m$ ,  $\hat{y}_i \in \{-1, 1\}$ .

# MSV.

- Supóngase que se tienen  $m$  individuos a los que se desea clasificar en  $\mathcal{C}_0, \mathcal{C}_1$  y para cada individuo sean  $\mathbf{x}_i \in \mathbb{R}^n$  su correspondiente vector de atributos  $i = 1, 2, \dots, m$  y el vector de etiquetas  $\hat{\mathbf{y}} = (\hat{y}_i)_{i=1}^m \in \mathbb{R}^m$ ,  $\hat{y}_i \in \{-1, 1\}$ .
- En  $\mathbb{R}^2$ :





# MSV.

# MSV.

- Modelo para MSV:

# MSV.

- Modelo para MSV:


$$y(\mathbf{x}|w_0, \mathbf{w}) = \mathbf{w}^T \mathbf{x} + w_0$$

# MSV.

- Modelo para MSV:

$$y(\mathbf{x}|w_0, \mathbf{w}) = \mathbf{w}^T \mathbf{x} + w_0$$

- En  $\mathbb{R}^2$ :



# MSV en $\mathbb{R}^2$ .

# MSV en $\mathbb{R}^2$ .

- En MSV se construye la recta  $\mathcal{P} = \{\mathbf{x} \in \mathbb{R}^2 \mid y(\mathbf{x}|\mathbf{w}_0, \mathbf{w}) = 0\}$  que cumpla con dos condiciones:

# MSV en $\mathbb{R}^2$ .

- En MSV se construye la recta  $\mathcal{P} = \{\mathbf{x} \in \mathbb{R}^2 \mid y(\mathbf{x}|w_0, \mathbf{w}) = 0\}$  que cumpla con dos condiciones:
  - Tenga distancia mínima  $d(\cdot, \cdot)$  al conjunto de individuos:

$$d(\mathcal{P}, \mathbf{x}_i) = \frac{|y(\mathbf{x}_i|w_0, \mathbf{w})|}{\|\mathbf{w}\|} = \frac{\hat{y}_i y_i}{\|\mathbf{w}\|}$$

## MSV en $\mathbb{R}^2$ .

- En MSV se construye la recta  $\mathcal{P} = \{\mathbf{x} \in \mathbb{R}^2 \mid y(\mathbf{x}|w_0, \mathbf{w}) = 0\}$  que cumpla con dos condiciones:
  - Tenga distancia mínima  $d(\cdot, \cdot)$  al conjunto de individuos:

$$d(\mathcal{P}, \mathbf{x}_i) = \frac{|y(\mathbf{x}_i|w_0, \mathbf{w})|}{\|\mathbf{w}\|} = \frac{\hat{y}_i y_i}{\|\mathbf{w}\|}$$

- Su margen sea máximo, considerando el margen  $\mathcal{M}_{w_0, \mathbf{w}}$  como:


$$\mathcal{M}_{w_0, \mathbf{w}} = \min_{i \in \{1, \dots, m\}} \{d(\mathcal{P}, \mathbf{x}_i)\}$$



# MSV en $\mathbb{R}^2$ .

## MSV en $\mathbb{R}^2$ .


- Se obtiene para este ejemplo la recta siguiente:



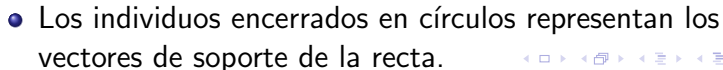
# MSV en $\mathbb{R}^2$ .

# MSV en $\mathbb{R}^2$ .

- Se obtiene para este ejemplo la recta siguiente:



- Se obtiene para este ejemplo la recta siguiente:



# MSV.

# MSV.

- Un individuo  $(\mathbf{x}_i, \hat{y}_i)$  está bien clasificado si se verifica:
  - $\mathbf{w}^T \mathbf{x}_i + w_0 \geq 1$  para  $\hat{y}_i = 1$
  - $\mathbf{w}^T \mathbf{x}_i + w_0 \leq -1$  para  $\hat{y}_i = -1$

# MSV.

- Un individuo  $(\mathbf{x}_i, \hat{y}_i)$  está bien clasificado si se verifica:
  - $\mathbf{w}^T \mathbf{x}_i + w_0 \geq 1$  para  $\hat{y}_i = 1$
  - $\mathbf{w}^T \mathbf{x}_i + w_0 \leq -1$  para  $\hat{y}_i = -1$
- Ambas condiciones se escriben:

$$\hat{y}_i(w^T \mathbf{x}_i + w_0) \geq 1 \quad \forall i = 1, 2, \dots, m$$



# MSV.

# MSV.

- Suponiendo que los datos son linealmente separables en el espacio  $\mathbb{R}^n$  el problema que se debe resolver es:

# MSV.

- Suponiendo que los datos son linealmente separables en el espacio  $\mathbb{R}^n$  el problema que se debe resolver es:

$$\min_{w_0, \mathbf{w}} \frac{1}{2} \|(w_0, \mathbf{w})\|^2 \quad \text{sujeto a:} \quad \hat{y}_i y_i \geq 1 \quad \forall i = 1, \dots, m$$

# MSV.

- Suponiendo que los datos son linealmente separables en el espacio  $\mathbb{R}^n$  el problema que se debe resolver es:

$$\min_{w_0, \mathbf{w}} \frac{1}{2} \|(w_0, \mathbf{w})\|^2 \quad \text{sujeto a: } \hat{y}_i y_i \geq 1 \quad \forall i = 1, \dots, m$$

- La regla para un nuevo individuo  $\mathbf{x}_N$  es: si  $y(\mathbf{x}_N | \mathbf{w}, w_0) \geq 0$  entonces se clasifica a  $\mathcal{C}_0$  y en otro caso a  $\mathcal{C}_1$


# Problema dual.

# Problema dual.

- La formulación dual del problema de optimización anterior tiene ventajas en la práctica por la posibilidad de usar funciones que permitan separar linealmente a los individuos.

# Problema dual.

- La formulación dual del problema de optimización anterior tiene ventajas en la práctica por la posibilidad de usar funciones que permitan separar linealmente a los individuos.



Ejemplos no linealmente separables

Ejemplos linealmente separables

# Problema dual.



# Problema dual.

- El problema dual es:

$$\min_{\lambda} \frac{1}{2} \lambda^T \hat{Y} X^T X \hat{Y} \lambda - \lambda^T e \quad \text{sujeito a:} \quad e^T \hat{Y} \lambda = 0, \quad \lambda \geq 0$$

donde:

# Problema dual.

- El problema dual es:

$$\min_{\lambda} \frac{1}{2} \lambda^T \hat{Y} X^T X \hat{Y} \lambda - \lambda^T e \quad \text{sujeito a:} \quad e^T \hat{Y} \lambda = 0, \quad \lambda \geq 0$$


donde:

- $e = (1)_{i=1}^m$
- $X = \begin{bmatrix} \mathbf{x}_1 & \cdots & \mathbf{x}_m \end{bmatrix}$
- $\hat{Y} = \text{diag}(\hat{y}_i)_{i=1}^m$
- $\lambda \in \mathbb{R}^m$  vector de multiplicadores de Lagrange.

# MSV en $\mathbb{R}^2$

# MSV en $\mathbb{R}^2$


- En el caso que se tenga una situación del tipo:



# MSV en $\mathbb{R}^2$

# MSV en $\mathbb{R}^2$

- Se definen para cada individuo  $\xi_i \geq 0 \quad \forall i = 1, 2, \dots, m$ :



# MSV.

# MSV.

- El problema de optimización en este caso:

$$\min_{w_0, \mathbf{w}} \frac{1}{2} \|(w_0, \mathbf{w})\|^2 + C e^T \boldsymbol{\xi}$$

$$\text{sujeto a: } \boldsymbol{\xi} \geq 0 \quad \hat{y}_i y_i \geq 1 - \xi_i \quad \forall i = 1, \dots, m$$



# MSV.

- El problema de optimización en este caso:

$$\min_{w_0, \mathbf{w}} \frac{1}{2} \|(w_0, \mathbf{w})\|^2 + C e^T \boldsymbol{\xi}$$

$$\text{sujeto a: } \boldsymbol{\xi} \geq 0 \quad \hat{y}_i y_i \geq 1 - \xi_i \quad \forall i = 1, \dots, m$$

donde:  $C > 0$  realiza un equilibrio entre sobreajuste y complejidad del modelo.

# MSV dual.

# MSV dual.

- El problema de optimización dual (POD):

$$\min_{\lambda_g} \frac{1}{2} \lambda_g^T \hat{Y} X^T X \hat{Y} \lambda_g - \lambda_g^T e$$

$$\text{sujeto a: } e^T \hat{Y} \lambda_g = 0, \quad 0 \leq \lambda_g \leq C$$

# MSV dual.

- El problema de optimización dual (POD):

$$\min_{\lambda_g} \frac{1}{2} \lambda_g^T \hat{Y} X^T X \hat{Y} \lambda_g - \lambda_g^T e$$

$$\text{sujeto a: } e^T \hat{Y} \lambda_g = 0, \quad 0 \leq \lambda_g \leq C$$

donde  $e, X, \hat{Y}$  son como antes y  $\lambda_g \in \mathbb{R}^m$  corresponde al vector de multiplicadores de Lagrange para la restricciones de la forma  $\hat{y}_i y_i \geq 1 - \xi_i \quad \forall i = 1, 2, \dots, m$

# Puntos interiores

# Puntos interiores

- Ambas formulaciones duales son problemas de optimización cuya función es cuadrática con restricciones lineales.

# Puntos interiores

- Ambas formulaciones duales son problemas de optimización cuya función es cuadrática con restricciones lineales.
- Métodos convencionales para resolver estos problemas han sido propuestos por el análisis numérico.

# Puntos interiores

- Ambas formulaciones duales son problemas de optimización cuya función es cuadrática con restricciones lineales.
- Métodos convencionales para resolver estos problemas han sido propuestos por el análisis numérico.
- Entre ellos se encuentran los métodos por puntos interiores.



# Puntos interiores

- Ambas formulaciones duales son problemas de optimización cuya función es cuadrática con restricciones lineales.
- Métodos convencionales para resolver estos problemas han sido propuestos por el análisis numérico.
- Entre ellos se encuentran los métodos por puntos interiores.
- La formulación por puntos interiores que veremos se realizará con el enfoque de función de barrera logarítmica.

# POD

# POD

- Realizando una asignación de variables y agregando la holgura  $s$  para la condición  $\lambda_g \leq C_e$  se tiene el problema de optimización:

# POD

- Realizando una asignación de variables y agregando la holgura  $s$  para la condición  $\lambda_g \leq C$  se tiene el problema de optimización:

$$\min_{x,y,s} \frac{y^T y}{2} - e^T x \quad \text{sujeto a:}$$

# POD

- Realizando una asignación de variables y agregando la holgura  $s$  para la condición  $\lambda_g \leq Ce$  se tiene el problema de optimización:

$$\min_{x,y,s} \quad \frac{y^T y}{2} - e^T x \quad \text{sujeto a:}$$

$$b^T x = 0$$

$$Ax - y = 0$$

$$x - Ce + s = 0$$

$$x \geq 0$$

$$s \geq 0.$$

# POD con función de barrera

# POD con función de barrera

- Utilizando la función de barrera logarítmica:

# POD con función de barrera

- Utilizando la función de barrera logarítmica:

$$\min_{x,y,s} \quad \frac{y^T y}{2} - e^T x - \mu_x \sum_{i=1}^m \log x_i - \mu_s \sum_{i=1}^m \log s_i \quad \text{sujeto a:}$$

$$b^T x = 0$$

$$Ax - y = 0$$

$$x - Ce + s = 0.$$



# Condiciones KKT para MSV secuencial

# Condiciones KKT para MSV secuencial

- Las condiciones KKT del problema anterior conducen a un sistema lineal de la forma:

$$Kd = -r(\mu),$$

# Condiciones KKT para MSV secuencial

- Las condiciones KKT del problema anterior conducen a un sistema lineal de la forma:

$$Kd = -r(\mu),$$

$$\text{con } K = \begin{bmatrix} X^{-1}Z + S^{-1}W & A^T & 0 & -b \\ A & -I_n & 0 & 0 \\ I_m & 0 & I_m & 0 \\ b^T & 0 & 0 & 0 \end{bmatrix}, \quad r$$

$$\text{conocidos, } \mu = \begin{bmatrix} \mu_x \\ \mu_s \end{bmatrix}.$$

# POD con función de barrera

# POD con función de barrera

- Algunas consideraciones para el problema anterior:

# POD con función de barrera

- Algunas consideraciones para el problema anterior:
  - La solución del problema se obtiene haciendo  $\mu_x, \mu_s \rightarrow 0$  en cada iteración.

# POD con función de barrera

- Algunas consideraciones para el problema anterior:
  - La solución del problema se obtiene haciendo  $\mu_x, \mu_s \rightarrow 0$  en cada iteración.
  - Esta solución es única.

# POD con función de barrera

- Algunas consideraciones para el problema anterior:
  - La solución del problema se obtiene haciendo  $\mu_x, \mu_s \rightarrow 0$  en cada iteración.
  - Esta solución es única.
  - Se agrega la corrección de Mehrotra para acelerar convergencia.



# POD con función de barrera

- Algunas consideraciones para el problema anterior:
  - La solución del problema se obtiene haciendo  $\mu_x, \mu_s \rightarrow 0$  en cada iteración.
  - Esta solución es única.
  - Se agrega la corrección de Mehrotra para acelerar convergencia.
  - La matriz  $K$  no posee una estructura para una formulación en paralelo....

# POD con función de barrera

- Algunas consideraciones para el problema anterior:
  - La solución del problema se obtiene haciendo  $\mu_x, \mu_s \rightarrow 0$  en cada iteración.
  - Esta solución es única.
  - Se agrega la corrección de Mehrotra para acelerar convergencia.
  - La matriz  $K$  no posee una estructura para una formulación en paralelo.... solución: *Using interior point methods for large scale support vector machine training* por K. Woodsend y J. Gondzio, 2009.

# POD (2) con función de barrera

## POD (2) con función de barrera

- Se realiza la misma asignación de variables pero no se agrega la holgura  $s$ :

## POD (2) con función de barrera

- Se realiza la misma asignación de variables pero no se agrega la holgura  $s$ :

$$\min_{x,y} \quad \frac{y^T y}{2} - e^T x - \mu \left[ \sum_{i=1}^m \log x_i + \log (C e_i - x_i) \right] \quad \text{sujeto a:}$$

$$A_y y + A_x x = 0$$

## POD (2) con función de barrera

- Se realiza la misma asignación de variables pero no se agrega la holgura  $s$ :

$$\min_{x,y} \quad \frac{y^T y}{2} - e^T x - \mu \left[ \sum_{i=1}^m \log x_i + \log (C e_i - x_i) \right] \quad \text{sujeto a:}$$

$$A_y y + A_x x = 0$$

donde:  $A_y = \begin{bmatrix} I_n \\ 0 \end{bmatrix}$ ,  $A_x = \begin{bmatrix} -A \\ -b^T \end{bmatrix}$ ,  $\mu > 0$  es el parámetro de barrera logarítmica.

# Condiciones KKT para MSV en paralelo

# Condiciones KKT para MSV en paralelo

- Las condiciones de KKT del problema anterior conducen a un sistema lineal de la forma:

$$Kd = -r$$



# Condiciones KKT para MSV en paralelo

- Las condiciones de KKT del problema anterior conducen a un sistema lineal de la forma:

$$Kd = -r$$

donde:  $K$  es una matriz simétrica, indefinida cuyas

entradas son conocidas y  $r = \begin{bmatrix} rc_y \\ rc_x(\mu) \\ r_b \end{bmatrix}$

## Condiciones KKT para MSV en paralelo

- Las condiciones de KKT del problema anterior conducen a un sistema lineal de la forma:

$$Kd = -r$$

donde:  $K$  es una matriz simétrica, indefinida cuyas

entradas son conocidas y  $r = \begin{bmatrix} r_{c_y} \\ r_{c_x}(\mu) \\ r_b \end{bmatrix}$

- El óptimo del problema anterior se encuentra haciendo  $\mu \rightarrow 0$  en cada iteración.

# Puntos interiores en paralelo

# Puntos interiores en paralelo

- Una ventaja del sistema anterior tiene que ver con la estructura de la matriz  $K$ :

$$K = \begin{bmatrix} H & -\hat{A}^T \\ -\hat{A} & 0 \end{bmatrix}$$

## Puntos interiores en paralelo

- Una ventaja del sistema anterior tiene que ver con la estructura de la matriz  $K$ :

$$K = \begin{bmatrix} H & -\hat{A}^T \\ -\hat{A} & 0 \end{bmatrix}$$

con  $H$  una matriz diagonal,  $\hat{A}$  rectangular.

## Puntos interiores en paralelo

- Una ventaja del sistema anterior tiene que ver con la estructura de la matriz  $K$ :

$$K = \begin{bmatrix} H & -\hat{A}^T \\ -\hat{A} & 0 \end{bmatrix}$$

con  $H$  una matriz diagonal,  $\hat{A}$  rectangular.

- Si se tienen  $p$  procesadores, entonces  $K$  se puede escribir

como sigue:  $K = \begin{bmatrix} H_1 & & & A_1^T \\ & H_2 & & A_2^T \\ & & \ddots & \vdots \\ & & & H_p & A_p^T \\ A_1 & A_2 & \dots & A_p & 0 \end{bmatrix}$

# Puntos interiores en paralelo

# Puntos interiores en paralelo

- Por otro lado, existe una factorización para  $K$  de la forma  $LD^T L$ :



## Puntos interiores en paralelo

- Por otro lado, existe una factorización para  $K$  de la forma  $LD^T L$ :

$$L = \begin{bmatrix} L_1 & & & \\ & \ddots & & \\ & & L_p & \\ L_{A_1} & \cdots & L_{A_p} & L_C \end{bmatrix}, \quad D = \begin{bmatrix} D_1 & & & \\ & \ddots & & \\ & & D_p & \\ & & & D_C \end{bmatrix}$$

# Puntos interiores en paralelo

# Puntos interiores en paralelo

- Se concluye lo siguiente:

$$H_i = L_i D_i L_i^T, \quad \therefore D_i = H_i, \quad L_i = I \quad (1)$$

$$L_{A_i} = A_i L_i^{-T} D_i^{-1} = A_i H_i^{-1} \quad (2)$$

$$C \equiv - \sum_{i=1}^p A_i H_i^{-1} A_i^T \quad (3)$$

$$= L_C D_C L_C^T. \quad (4)$$

# Puntos interiores en paralelo

- Se concluye lo siguiente:

$$H_i = L_i D_i L_i^T, \quad \therefore D_i = H_i, \quad L_i = I \quad (1)$$

$$L_{A_i} = A_i L_i^{-T} D_i^{-1} = A_i H_i^{-1} \quad (2)$$

$$C \equiv - \sum_{i=1}^p A_i H_i^{-1} A_i^T \quad (3)$$

$$= L_C D_C L_C^T. \quad (4)$$

Los productos (2) se realizan en cada uno de los procesadores y la suma (3) y la factorización (4) se realiza en un sólo procesador.

# Puntos interiores en paralelo

# Puntos interiores en paralelo

- Con la factorización  $K = LDL^T$  se resuelve el sistema:

# Puntos interiores en paralelo

- Con la factorización  $K = LDL^T$  se resuelve el sistema:

$$LDL^T \begin{bmatrix} d_z \\ d_\lambda \end{bmatrix} = - \begin{bmatrix} r_c \\ r_b \end{bmatrix},$$

donde  $z = \begin{bmatrix} y \\ x \end{bmatrix}$ ,  $rc = \begin{bmatrix} rc_y \\ rc_x \end{bmatrix}$  también en paralelo.

# Puntos interiores en paralelo



## Puntos interiores en paralelo

- Se tiene:

$$d\lambda'' = L_C^{-1} \left( r_b - \sum_{i=1}^p L_{A_i} r_{c_i} \right) \quad (5)$$

$$d\lambda' = D_C^{-1} d\lambda'' \quad (6)$$

$$d\lambda = L_C^{-T} d\lambda' \quad (7)$$

$$dz_i' = D_i^{-1} r_{c_i} \quad (8)$$

$$dz_i = dz_i' - L_{A_i}^T d\lambda. \quad (9)$$

## Puntos interiores en paralelo

- Se tiene:

$$d\lambda'' = L_C^{-1} \left( r_b - \sum_{i=1}^p L_{A_i} r_{c_i} \right) \quad (5)$$

$$d\lambda' = D_C^{-1} d\lambda'' \quad (6)$$

$$d\lambda = L_C^{-T} d\lambda' \quad (7)$$

$$dz_i' = D_i^{-1} r_{c_i} \quad (8)$$

$$dz_i = dz_i' - L_{A_i}^T d\lambda. \quad (9)$$

En cada procesador se lleva a cabo el producto  $L_{A_i} r_{c_i}$  y en un sólo procesador se realiza (5), (6), (7). El vector  $d\lambda$  se transmite a cada procesador en los que se realiza el producto  $D_i^{-1} r_{c_i}$  y (9).

# Bases de datos

# Bases de datos

- Criterios de selección:

# Bases de datos

- Criterios de selección:
  - Dimensiones.

# Bases de datos

- Criterios de selección:
  - Dimensiones.
  - Sin valores faltantes.

# Bases de datos

- Criterios de selección:
  - Dimensiones.
  - Sin valores faltantes.
  - De acuerdo a las características de la computadora (procesador con dos núcleos y 8 gb en RAM)

# Bases de datos

- Criterios de selección:
  - Dimensiones.
  - Sin valores faltantes.
  - De acuerdo a las características de la computadora (procesador con dos núcleos y 8 gb en RAM)
  - Se elige la tasa de clasificación incorrecta como medida de precisión.



# Avisos de granja

# Avisos de granja

- Avisos de texto en 12 sitios de internet.

# Avisos de granja

- Avisos de texto en 12 sitios de internet.
- Modelo por bolsa de palabras.

# Avisos de granja

- Avisos de texto en 12 sitios de internet.
- Modelo por bolsa de palabras.
- Etiquetas binarias (aprueba o no el aviso)

# Avisos de granja

- Avisos de texto en 12 sitios de internet.
- Modelo por bolsa de palabras.
- Etiquetas binarias (aprueba o no el aviso)
- 4,143 renglones y 54,877 columnas.

# Avisos de granja

- Avisos de texto en 12 sitios de internet.
- Modelo por bolsa de palabras.
- Etiquetas binarias (aprueba o no el aviso)
- 4,143 renglones y 54,877 columnas.
- Se divide en un 10 % para el conjunto de prueba

# Avisos de granja

	MSV	RL
Entrenamiento	1.072e-3	2.681 e-3
Prueba	7.729e-2	5.797e-2

# Trombina



# Trombina

- Compuestos presentes en la sangre.

# Trombina

- Compuestos presentes en la sangre.
- Etiquetas binarias (el compuesto se une o no a la trombina)

# Trombina

- Compuestos presentes en la sangre.
- Etiquetas binarias (el compuesto se une o no a la trombina)
- El conjunto de entrenamiento tiene 1,909 renglones y 139,351 columnas

# Trombina

- Compuestos presentes en la sangre.
- Etiquetas binarias (el compuesto se une o no a la trombina)
- El conjunto de entrenamiento tiene 1,909 renglones y 139,351 columnas
- El conjunto de prueba tiene 634 renglones.

# Trombina

	MSV	RL
Entrenamiento	1.047e-3	2.2e-2
Prueba	2.3659e-1	2.3659e-1

# Comentarios.

# Comentarios.

- La conexión entre nodos de un clúster, la transmisión de datos entre ellos y el manejo de memoria es posible consultar en la referencia de Woodsend y Gondzio.

## Comentarios.

- La conexión entre nodos de un clúster, la transmisión de datos entre ellos y el manejo de memoria es posible consultar en la referencia de Woodsend y Gondzio.
- La formulación dual de la MSV permite considerar problemas de la forma:

$$\begin{aligned} \min_{\lambda_g} \quad & \frac{1}{2} \lambda_g^T \hat{Y} \hat{K} \hat{Y} \lambda_g - \lambda_g^T e \\ \text{sujeto a:} \quad & e^T \hat{Y} \lambda_g = 0, \quad 0 \leq \lambda_g \leq C \end{aligned}$$



## Comentarios.

- La conexión entre nodos de un clúster, la transmisión de datos entre ellos y el manejo de memoria es posible consultar en la referencia de Woodsend y Gondzio.
- La formulación dual de la MSV permite considerar problemas de la forma:

$$\min_{\lambda_g} \frac{1}{2} \lambda_g^T \hat{Y} \hat{K} \hat{Y} \lambda_g - \lambda_g^T e$$

$$\text{sujeto a: } e^T \hat{Y} \lambda_g = 0, \quad 0 \leq \lambda_g \leq C$$

donde  $\hat{K}$  es una matriz con elementos  $\hat{K}_{i,j} = \hat{K}(\mathbf{x}_i, \mathbf{x}_j)$  y  $\hat{K}(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$ ,  $\phi$  no lineal.

## Comentarios.

- La conexión entre nodos de un clúster, la transmisión de datos entre ellos y el manejo de memoria es posible consultar en la referencia de Woodsend y Gondzio.
- La formulación dual de la MSV permite considerar problemas de la forma:

$$\min_{\lambda_g} \frac{1}{2} \lambda_g^T \hat{Y} \hat{K} \hat{Y} \lambda_g - \lambda_g^T e$$

$$\text{sujeto a: } e^T \hat{Y} \lambda_g = 0, \quad 0 \leq \lambda_g \leq C$$

donde  $\hat{K}$  es una matriz con elementos  $\hat{K}_{i,j} = \hat{K}(\mathbf{x}_i, \mathbf{x}_j)$  y  $\hat{K}(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$ ,  $\phi$  no lineal.

- En la referencia de Woodsend y Gondzio se trabaja este enfoque para realizar en paralelo MSV.